

Tekoälyn rooli suurten datamassojen analysoinnissa ja sen hyödyntäminen kaupalliseen päättöksentekoon

Tietotekniikka
Tietotekniikan laitos, Teknillinen tiedekunta
Kandidaatintutkielma

Laatija:
Riku Lauttia

Tammikuu 2025

Turun yliopiston laatu järjestelmän mukaisesti tämän julkaisun alkuperäisyys on tarkastettu
Turnitin OriginalityCheck -järjestelmällä.

Tekoäly on noussut keskeiseen asemaan suurten datamassojen analysoinnissa, tarjoten suurille yrityksille mahdollisuuden jalostaa valtavia tietomääriä arvokkaiksi liiketoimintatiedoiksi. Suurten datamäärien tehokas käsittely ja analysointi on tullut välttämättömäksi yritysten kilpailuedun saavuttamiseksi, ja tekoäly mahdollistaa monimutkaistenkin datarakenteiden ymmärtämisen ja hyödyntämisen. Tämä auttaa yrityksiä tunnistamaan piileviä trendejä, ennustamaan markkinakehitystä ja tekemään dataan perustuvia päätöksiä nopeammin ja tarkemmin.

Tutkielma perustuu kirjallisuuskatsaukseen, jossa analysoidaan tekoälyn soveltamista suurten datamassojen analysointiin sekä sen vaikutusta kaupalliseen päätöksentekoon suurissa yrityksissä. Analyysissä keskitytään erityisesti ajankohtaisiin tutkimuksiin, jotka käsittelevät tekoälyn roolia datan esikäsittelyssä, validoinnissa ja optimoinnissa. Keskeiset havainnot osoittavat, että tekoäly voi merkittävästi parantaa suurten yritysten päätöksentekoa tehostamalla data-analyysiprosesseja ja tarjoamalla syvällisempiä oivalluksia liiketoimintaympäristöstä. Tämän myötä voidaan myös vähentää inhimillisiä virheitä ja parantaa sekä tehostaa resurssien käyttöä.

Avainsanat: tekoäly, koneoppiminen, suurten datamassojen analysointi, kaupallinen päätöksenteko, suuryritykset, data-analyysi, teknologioiden soveltaminen

Sisällysluettelo

1	JOHDANTO	1
2	TEKOÄLY SUURTEN DATAMASSOJEN ANALYSOINNISSA	3
2.1	Tekoäly ja datan käsittely	4
2.1.1	Big Data -haasteet ja tekoälyn merkitys	4
2.1.2	Datan esikäsittelyn vaiheet ja merkitys	6
2.1.3	Pilvipalvelut ja skaalautuva datan käsittely	6
2.2	Koneoppimisen hyödyntäminen datan analysoinnissa	7
2.2.1	Koneoppimisen perusperiaatteet ja oppimismenetelmät	7
2.2.2	Algoritmit ja mallintaminen suurille datamassoille	8
2.2.3	Syväoppimisen rooli analysoinnissa	9
2.2.4	Koneoppimisen työkalut	9
2.2.5	Koneoppimisen sovelluskohteet	10
2.2.6	Käytännön esimerkit	11
2.3	Yhteenveto	12
3	TEKOÄLYN HYÖDYNTÄMINEN KAUPALLISESSA PÄÄTÖKSENTEOSSA	13
3.1	Käytännön sovellukset päätöksenteossa	13
3.1.1	Markkinatrendien analyysi ja ennustaminen	13
3.1.2	Asiakaskäyttäytymisen analyysi ja personointi	14
3.1.3	Resurssien optimointi ja -hallinta	15
3.1.4	Riskienhallinta ja petosten havaitseminen	17
3.1.5	Strategisen päätöksenteon tukeminen	17
3.2	Kaupalliset hyödyt ja haasteet	19
3.2.1	Tekoälyn tuomat tehokkuusparannukset	19
3.2.2	Kilpailuedun saavuttaminen tekoälyn avulla	19
3.2.3	Teknologiset haasteet ja legacy-järjestelmät	20
3.2.4	Infrastruktuurivaatimukset ja ympäristövaikutukset	21
3.2.5	Tekoälyn käyttöönoton haasteet ja strategiat	22
3.2.6	Eettisyys ja Tietosuoja	23
3.3	Yhteenveto	23
4	YHTEENVETO	25
	LÄHTEET	27

1 Johdanto

Tekoälyn nopea kehitys on mullistanut tapoja, joilla suuret yritykset käsittelevät ja analysoivat valtavia datamääriä. Suurten datamassojen tehokas analysointi on tullut välttämättömäksi kilpailuedun saavuttamiseksi globaalissa liiketoimintaympäristössä (Kirola et al., 2023; Dandekar et al., 2024). Perinteiset analyysimenetelmät eivät usein riitä käsittelemään datan kasvavaa volyymia, monimuotoisuutta ja nopeutta, mikä korostaa tekoälyn ja koneoppimisen merkitystä nykyaikaisessa data-analytiikassa (Dandekar et al., 2024).

Tekoälyn sovellukset, kuten ennakoiva analytiikka, luonnollisen kielen käsittely ja neuroverkot, mahdollistavat datan syvällisemmän ymmärtämisen ja piilevien mallien tunnistamisen (Jamalpur et al., 2024). Esimerkiksi koneoppimismallien avulla yritykset voivat analysoida markkinatrendejä, ennustaa asiakaskäyttäytymistä ja optimoida resurssien käyttöä, mikä johtaa parempiin strategisiin päätöksiin (Johri et al., 2023; Sun et al., 2022). Näiden teknologioiden tehokas hyödyntäminen voi merkittävästi parantaa yritysten operatiivista tehokkuutta ja päätöksenteon laatua.

Tämän tutkimuksen tavoitteena on selvittää, miten tekoälyn eri teknologioita voidaan soveltaa tehokkaasti suurten datamassojen analysointiin sekä tutkia niiden vaikutusta suurten yritysten kaupalliseen päätöksentekoon. Työssä keskitytään erityisesti tekoälyn ja koneoppimisen konkreettisiin sovelluksiin datan esikäsittelyssä, analysoinnissa ja optimoinnissa, sekä tarkastellaan haasteita ja ratkaisuja näiden teknologioiden implementoinnissa suurissa organisaatioissa.

Tutkimuksessa pyritään vastaamaan seuraaviin kysymyksiin:

- TK1: Millä tavoin tekoälyn ja koneoppimisen teknologioita voidaan soveltaa tehokkaasti suurten datamassojen analysointiin?
- TK2: Kuinka tekoälyä ja koneoppimista voidaan hyödyntää suurten yritysten kaupallisen päätöksenteon tukena?

Tässä työssä keskitytään suuriin yrityksiin, jotka toimivat datavetoisilla toimialoilla ja kohtaavat haasteita suurten datamäärien käsittelyssä. Tutkimuksessa ei tarkastella pk-yritysten

näkökulmaa, vaan painopiste on erityisesti suurten organisaatioiden tarpeissa ja mahdollisuuksissa. Tekoälyn ja koneoppimisen sovelluksista tarkastellaan erityisesti liiketoiminnan tehostamiseen liittyviä toimintoja, kuten strategista suunnittelua, markkina-analyysia ja asiakaskäyttäytymisen ennustamista (Jamalpur et al., 2024; Johri et al., 2023).

Tämä tutkielma on kirjallisuuskatsaus, jossa analysoidaan tekoälyn ja koneoppimisen hyödyntämistä suurten datamassojen käsittelyssä ja tämän hyödyntäminen kaupalliseen päätöksentekoon suurissa yrityksissä. Aineisto on koottu tieteellisistä lähteistä, kuten IEEE Xplore, ACM Digital Library, Google Scholar ja ScienceDirect. Hakuprosessissa käytettiin hakulauseita, kuten "(AI OR artificial intelligence) AND ("machine learning" OR ML) AND (big data) AND (commercial decision-making)". Analyysiin valittiin erityisesti vuosina 2020–2024 julkaistuja tutkimuksia, jotka käsittelevät ajankohtaisia tekoälyn sovelluksia suurten yritysten liiketoiminnassa.

Työ koostuu neljästä pääluvusta. Johdannon jälkeen luvussa 2 käsitellään tekoälyn ja koneoppimisen peruseräitä ja niiden hyödyntämistä suurten datamassojen analysoinnissa. Luvussa 3 tarkastellaan tekoälyn ja koneoppimisen käytännön sovelluksia kaupallisessa päätöksenteossa, sekä hyötyjä ja haasteita. Viimeisessä luvussa 4 esitetään työn yhteenveto, jossa käydään läpi keskeiset läpikäytyt asiat.

2 Tekoäly suurten datamassojen analysoinnissa

Tekoäly (AI) sekä koneoppiminen (ML) ovat viime vuosina nousseet keskeisiksi tekijöiksi suurten datamassojen käsittelyssä ja analysoinnissa. Suuret datamäärät, eli big data, ovat monimutkaisia ja usein rakenteettomia tietokokonaisuuksia, joita perinteiset tietojenkäsittelymenetelmät eivät pysty tehokkaasti käsittelemään (Kirola et al., 2023). AI ja ML tarjoavat ratkaisuja näihin haasteisiin mahdollistamalla datan automaattisen käsittelyn, analysoinnin ja hyödyntämisen liiketoiminnassa. Suurten datamassojen analysoinnin merkitys kasvaa jatkuvasti, sillä organisaatiot kohtaavat yhä enemmän dataa, joka on hajautettu eri muotoihin ja lähteisiin. Datan volyymin, nopeuden ja monimuotoisuuden kasvaessa perinteiset menetelmät eivät pysty vastaamaan modernin dataympäristön vaatimuksiin. Tämä korostaa tekoällyn ja koneoppimisen keskeistä roolia datan analysoinnissa, koska nämä teknologiat pystyvät skaalautumaan ja automatisoimaan datan käsittelyn (Kirola et al., 2023).

Tekoäly (AI) viittaa järjestelmiin, jotka kykenevät suorittamaan tehtäviä, jotka normaalisti vaatisivat ihmisen älykkyyttä. Näihin kuuluvat muun muassa mallien tunnistaminen, ennusteiden tekeminen ja päätöksenteko. AI mahdollistaa datan tehokkaamman ja älykkäämmän hyödyntämisen liiketoiminnassa, kuten markkina-analyysissä ja asiakaskäyttäytymisen ennustamisessa (Jamalpur et al., 2024). Kun tutkielmassa käsitellään tekoälyä viitataan laajempiin teknologisiin sovelluksiin, joihin sisältyvät esimerkiksi tekoälyratkaisut ja järjestelmät, jotka hyödyntävät koneoppimisen malleja osana kokonaisuutta.

Koneoppiminen (ML), joka on tekoällyn osa-alue, tarkoittaa algoritmien kykyä oppia ja parantaa suoritustaan ilman erillistä ohjelmointia. ML avulla tietokoneet voivat analysoida valtavia määriä dataa ja tehdä ennusteita tai löytää piileviä kaavoja. Koneoppimismallit oppivat historiadatan perusteella ja tuottavat analyysin, joka voi auttaa yrityksiä tekemään strategisia päätöksiä tehokkaammin (Kirola et al., 2023). Kun tutkielmassa käsitellään koneoppimista, keskitytään erityisesti datan analysointiin, mallintamiseen ja ennusteisiin liittyviin menetelmiin ja algoritmeihin, jotka ovat tekoällyn konkreettinen ilmentymä datan käsittelyssä.

Suuret datamassat (big data) puolestaan tarkoittavat datakokonaisuuksia, jotka ovat liian laajoja ja monimutkaisia perinteisille tietokantajärjestelmille. Big datan hallintaan ja analysointiin tarvitaan edistyneitä teknologioita ja menetelmiä, kuten AI ja ML, jotta datasta saadaan hyödyllistä tietoa liiketoiminnan tarpeisiin (Dandekar et al., 2024).

Tämän luvun tarkoituksena on selvittää, miten tekoälyä ja koneoppimista voidaan hyödyntää suurten datamassojen käsittelyssä ja analysoinnissa. Ensimmäisessä alaluvussa (2.1) käsitellään tekoälyn roolia datan käsittelyssä, ja toisessa alaluvussa (2.2) keskitytään koneoppimisen tarjoamiin ratkaisuihin datan analysoinnissa. Nämä teknologiat ovat avainasemassa, kun suuret yritykset pyrkivät hyödyntämään suurten datamassojen tuottaman tiedon strategisesti kaupallisen päätöksenteon tukena.

2.1 Tekoäly ja datan käsittely

Tekoälyn merkitys datan käsittelyssä on kasvanut oleellisesti erityisesti suurten datamassojen analysoinnin yhteydessä. Tekoäly tarjoaa mahdollisuuden automatisoida monimutkaiset prosessit, jotka liittyvät datan keräämiseen, käsittelyyn ja analysointiin. Perinteiset datan käsittely menetelmät eivät kykene käsittelemään suuria ja monimuotoisia datakokonaisuuksia, jotka muodostuvat esimerkiksi internetin ja IoT-laitteiden tuottamasta datasta. Tekoälyn sovellukset, kuten koneoppiminen, neuroverkot ja luonnollisen kielen käsittely (NLP), mahdollistavat datan syvällisemmän analysoinnin ja hyödyntämisen liiketoiminnassa (Pani et al., 2021). Pani et al. (2021) tuovat esiin, että tekoälyn sovellukset, erityisesti pilvipohjaiset, ovat erittäin tehokkaita big data -analytiikassa. Pilvipalvelut tarjoavat skaalautuvan ja kustannustehokkaan tavan hallita ja analysoida suuria datamassoja, jotka ovat usein hajautettuja eri lähteisiin. Lisäksi tekoälyratkaisut, kuten syväoppiminen, mahdollistavat valtavien tietomäärien reaaliaikaisen analyysin ja päätöksenteon tarkkuuden ja nopeuden lisäämisen liiketoiminnassa.

2.1.1 Big Data -haasteet ja tekoälyn merkitys

Suurten datamassojen, eli big datan, hallinta on monimutkainen tehtävä, joka edellyttää erityisiä teknologioita ja menetelmiä. Big dataa määrittelevät usein niin kutsutut "5 V": Volume, Velocity, Variety, Veracity ja Value. Nämä käsitteet kuvaavat datan ominaisuuksia

ja haasteita, joita yritykset kohtaavat pyrkiessään hyödyntämään tätä dataa liiketoiminnassaan (Kirola et al., 2023). *Volume (Volyymi)* on suurten datamassojen keskeisin ominaisuus eli datan valtava määrä. IoT-laitteet, sosiaalinen media ja muut digitaalisen vuorovaikutuksen kanavat tuottavat jatkuvasti enemmän dataa. Perinteiset tietokannat ja analyysimenetelmät eivät pysty käsittelemään tällaisia määriä tehokkaasti, mikä korostaa tekoälyteknologioiden merkitystä datan hallinnassa. *Velocity (Nopeus)* tarkoittaa sitä, että dataa ei pelkästään tuoteta valtavia määriä, vaan sitä tuotetaan ja siirretään erittäin nopeasti. Tämä asettaa haasteita datan reaaliaikaiselle käsittelylle. Tekoäly pystyy kuitenkin käsittelemään dataa nopeasti ja tuottamaan analyysin lähes välittömästi, mikä auttaa yrityksiä tekemään nopeita päätöksiä (Jamalpur et al., 2024). *Variety (Monimuotoisuus)*: Big data ei ole homogeenista. Se voi olla strukturoitua, kuten tietokantatauluja, tai strukturoimatonta, kuten tekstiä, kuvia ja videoita. Tämä monimuotoisuus asettaa haasteita datan esikäsittelylle ja analysoinnille, mutta tekoäly pystyy käsittelemään monimutkaisia datakokonaisuuksia tehokkaasti erilaisilla algoritmeilla. *Veracity (Totuudenmukaisuus)*: Suurten datamassojen luonteeseen kuuluu myös epävarmuus ja virheellisyys. Datan laatu voi vaihdella huomattavasti, mikä vaikuttaa analyysin tarkkuuteen ja luotettavuuteen. Tekoäly pystyy parantamaan datan tarkkuutta ja luotettavuutta tunnistamalla poikkeavuuksia ja virheitä esikäsittelyvaiheessa (Dandekar et al., 2024). *Value (Arvo)*: Suuri määrä dataa itsessään ei ole arvokasta, ellei sitä voida analysoida ja hyödyntää liiketoiminnan päätöksenteossa. Tekoälyllä on keskeinen rooli datan arvon tuottamisessa, sillä sen avulla voidaan tunnistaa datasta piileviä trendejä ja kaavoja, jotka voivat johtaa parempiin liiketoimintapäätöksiin (Dandekar et al., 2024, Kirola et al., 2023).

Datan valtava määrä, nopeus ja monimuotoisuus tekevät big datan analysoinnista haasteellista. Perinteiset analyysimenetelmät ovat usein liian hitaita ja rajoittuneita käsittelemään näitä ominaisuuksia, joten tekoälyyn perustuvat ratkaisut ovat välttämättömiä. Dandekar et al. (2024) korostavat, että big data -analytiikan haasteet liittyvät ennen kaikkea datan laatuun, yksityisyyteen ja tietoturvaan. Tulevaisuuden trendit keskittyvät näiden haasteiden ratkaisemiseen, erityisesti koneoppimisen ja tekoälyn kehittyessä entistä tehokkaammiksi. Yksi merkittävimmistä haasteista on datan hajautuminen eri lähteisiin, mikä tekee sen yhdistämisestä ja analysoimisesta monimutkaista. Lisäksi datan laatu voi vaihdella suuresti, mikä vaatii tehokkaita esikäsittelymenetelmiä. Tekoälyn avulla voidaan kuitenkin automatisoida monimutkaisia prosesseja, kuten datan puhdistaminen ja muuntaminen analyysikelpoiseen muotoon, mikä mahdollistaa tarkemmat ja nopeammat analyysitulokset.

2.1.2 Datan esikäsittelyn vaiheet ja merkitys

Datan esikäsittely on olennainen vaihe ennen kuin suuria datamassoja voidaan analysoida tekoälyn ja koneoppimisen avulla. Ilman esikäsittelyä raakadatan laatu voi heikentää analyysin tarkkuutta ja johtaa virheellisiin päätelmiin. Esikäsittelyprosessin tarkoituksena on parantaa datan laatua tekemällä siitä puhtaampaa, yhtenäisempää ja helpommin käsiteltävää. Tämä vaihe kattaa useita toimenpiteitä, kuten datan puhdistuksen, normalisoinnin ja muuntamisen analyysikelpoiseen muotoon (Kirola et al., 2023). Datan puhdistus sisältää virheellisten tai puuttuvien tietojen poistamisen tai korjaamisen. Tämä on erityisen tärkeää, koska puutteellinen tai ristiriitainen data voi vääristää koneoppimismallien tuloksia. Normalisointi on toinen keskeinen esikäsittelyn osa-alue, jossa eri mittayksiköt muunnetaan samaan skaalaan, jotta algoritmit pystyvät käsittelemään dataa johdonmukaisesti. Esikäsittelyyn kuuluu myös datan muuntaminen, kuten kategorisen datan muuttaminen numeeriseen muotoon, mikä helpottaa analysointia koneoppimismalleilla.

2.1.3 Pilvipalvelut ja skaalautuva datan käsittely

Suurten datamassojen käsittelyyn tarvitaan tehokkaita ja skaalautuvia järjestelmiä. Hajautetut järjestelmät ja rinnakkaisprosessointi ovat keskeisiä tekniikoita, jotka mahdollistavat datan käsittelyn suurilla volyymeilla ja nopeudella. Hajautetut tietokannat, kuten Apache Hadoop ja Apache Spark, ovat esimerkkejä teknologioista, jotka hyödyntävät rinnakkaisprosessointia suurten datamassojen analysointiin (Kirola et al., 2023). Hadoop on hajautettu tietojenkäsittelyjärjestelmä, joka mahdollistaa suurten datamäärien käsittelyn useissa rinnakkaisissa solmuissa. Sen perusrakenne perustuu MapReduce-ohjelmointimalliin, joka hajauttaa datan käsittelyn useisiin osiin ja yhdistää tulokset tehokkaasti. Hadoop on erityisen hyödyllinen tilanteissa, joissa data on hajautettu useisiin eri lähteisiin ja järjestelmiin (Dandekar et al., 2024). Spark puolestaan on hajautettu tietojenkäsittelyjärjestelmä, joka tarjoaa nopeamman ja joustavamman tavan käsitellä dataa verrattuna perinteiseen MapReduceen. Spark hyödyntää muistinvaraista käsittelyä, mikä parantaa suorituskkyä ja mahdollistaa reaaliaikaisen datan analysoinnin. Tämä tekee siitä erityisen hyödyllisen suurten ja monimutkaisten datakokonaisuuksien analysoinnissa (Dandekar et al., 2024).

Pilvipalvelut ovat toinen keskeinen tekijä skaalautuvassa datankäsittelyssä. Pilvipalvelut tarjoavat joustavan ja kustannustehokkaan tavan tallentaa, käsitellä ja analysoida suuria datamassoja. Yksi pilvipalveluiden suurimmista eduista on niiden kyky skaalautua yrityksen

tarpeiden mukaan. Tämä tarkoittaa, että yritykset voivat lisätä tai vähentää käytettävissä olevia resursseja datan analysointiin reaaliaikaisesti (Pani et al., 2024). Dandekar et al. (2024) esittävät, että pilvipohjaiset tekoäly- ja koneoppimisjärjestelmät ovat mullistaneet tapoja, joilla yritykset voivat analysoida suuria datamassoja. Pilvialustat, kuten Amazon Web Services (AWS) ja Microsoft Azure, tarjoavat AI- ja ML-pohjaisia palveluita, jotka integroivat koneoppimismallit ja datan käsittelyn saumattomasti. Pilvipalveluiden avulla yritykset voivat vähentää infrastruktuurikustannuksia ja keskittyä datan hyödyntämiseen strategisesti ilman raskasta IT-ylläpitoa.

2.2 Koneoppimisen hyödyntäminen datan analysoinnissa

Koneoppiminen on tekoälyn osa-alue, joka keskittyy algoritmeihin, jotka kykenevät oppimaan ja parantamaan suoritustaan ilman erillistä ohjelmointia. Koneoppimisen avulla tietokoneet voivat analysoida suuria määriä dataa ja tehdä ennusteita tai tunnistaa piileviä kaavoja. Koneoppimismallit oppivat historiadatan perusteella ja tuottavat analyysin, joka voi auttaa yrityksiä tekemään strategisia päätöksiä tehokkaammin (Jamalpur et al., 2024). Koneoppiminen voidaan jakaa kolmeen pääkategoriaan: ohjattu oppiminen, ohjaamaton oppiminen ja vahvistusoppiminen. Jokainen näistä kategorioista soveltuu erityyppisten ongelmien ratkaisemiseen ja niitä käytetään laajasti big data -analytiikassa.

2.2.1 Koneoppimisen peruseriaatteet ja oppimismenetelmät

Ohjattu oppiminen (supervised learning) on yksi yleisimmin käytetyistä koneoppimisen menetelmistä. Tässä lähestymistavassa algoritmi koulutetaan syöttämällä sille dataa, jossa on tunnetut vastaukset tai opetusdatan oikeat vastaukset. Algoritmi oppii mallintamaan syötteen ja vastauksen välisen yhteyden, minkä jälkeen sitä voidaan käyttää ennustamaan uusia tuloksia tuntemattomista syötteistä. Esimerkkejä ohjatusta oppimisesta ovat luokittelu- ja regressioalgoritmit, kuten logistinen regressio ja päätöspuut. Ohjattua oppimista käytetään usein ennustaviin analyysihin, kuten markkinatrendien ennustamiseen ja asiakaskäyttäytymisen analysointiin (Kirola et al., 2023). Ohjaamaton oppiminen (unsupervised learning) eroaa ohjatusta oppimisesta siinä, että data ei ole etiketoitu, eli algoritmi ei tiedä oikeita vastauksia. Algoritmi yrittää sen sijaan tunnistaa malleja tai rakenteita datasta itsenäisesti. Ohjaamattoman oppimisen sovelluksia ovat esimerkiksi klusterointimenetelmät, joissa data ryhmitellään samankaltaisten ominaisuuksien perusteella,

ja anomalian havaitseminen, joka pyrkii tunnistamaan poikkeavuuksia suurista datamääristä. Esimerkkejä ohjaamattomista oppimismenetelmistä ovat k-means-klusterointi ja pääkomponenttianalyysi (Kirola et al., 2023). Vahvistusoppiminen (reinforcement learning) on oppimistekniikka, jossa algoritmi oppii tekemään päätöksiä palkkioiden ja rangaistusten perusteella. Algoritmi vuorovaikuttaa ympäristön kanssa, ja se pyrkii maksimoimaan kumulatiivisen palkkion pitkällä aikavälillä. Vahvistusoppimista käytetään erityisesti dynaamisissa ympäristöissä, joissa päätöksenteon tulee olla sopeutuvaa ja joustavaa, kuten robotiikassa ja itseohjautuvissa ajoneuvoissa (Kirola et al., 2023).

2.2.2 Algoritmit ja mallintaminen suurille datamassoille

Suurten datamassojen analysointi vaatii erityisiä, skaalautuvia algoritmeja, jotka pystyvät käsittelemään valtavia määriä dataa tehokkaasti ja tarkasti. Näissä tilanteissa perinteiset analyysimenetelmät eivät riitä, joten koneoppimiseen perustuvat algoritmit ovat välttämättömiä, jotta datasta voidaan saada hyödyllistä tietoa. Koneoppiminen tarjoaa useita erilaisia algoritmeja ja menetelmiä, joilla voidaan analysoida ja optimoida suurten datamassojen käyttöä eri sovelluksissa. Suurten datamassojen käsittelyssä käytettävien algoritmien on oltava skaalautuvia, jotta ne voivat hyödyntää suuria tietomääriä ja vaihtelevaa datan rakennetta. Skaalautuvuus tarkoittaa, että algoritmi voi sopeutua käsittelemään yhä suurempia datamääriä ilman merkittävää suorituskyvyn heikkenemistä. Tähän soveltuvia algoritmeja ovat esimerkiksi päätöspuut, klusterointimenetelmät ja syväoppiminen. Päätöspuut ovat yksi suosituimmista algoritmeista suurten datamassojen käsittelyssä, koska ne ovat yksinkertaisia, tulkittavia ja tehokkaita monimutkaisessa ympäristössä. Päätöspuualgoritmi rakentaa sarjan ehtoihin perustuvia sääntöjä, jotka jakavat dataa eri luokkiin tai ennustavat jatkuvia arvoja. Tämä tekee päätöspuista käyttökelpoisia sekä luokittelussa että regressiotehtävissä. Päätöspuut voidaan optimoida suuria datamääriä varten käyttämällä menetelmiä, kuten satunnaismetsiä (random forests) ja gradienttivahvistettuja malleja, jotka parantavat suorituskykyä ja ennustetarkkuutta. Klusterointimenetelmät, kuten k-means-klusterointi ja hierarkkinen klusterointi, ovat erityisen hyödyllisiä silloin, kun dataa ei ole etukäteen luokiteltu, ja halutaan löytää luonnollisia ryhmiä tai klustereita datasta. Klusteroinnilla voidaan tunnistaa samankaltaisia ryhmiä suurista tietokokonaisuuksista, mikä auttaa kohdentamaan esimerkiksi markkinointitoimenpiteitä tai analysoimaan asiakaskäyttäytymistä (Johri et al., 2023).

2.2.3 Syväoppimisen rooli analysoinnissa

Syväoppiminen (deep learning) on yksi nykyaikaisimmista ja tehokkaimmista menetelmistä suurten ja monimutkaisten datamassojen analysointiin. Se perustuu monikerroksisiin neuroverkkoihin, jotka oppivat automaattisesti tunnistamaan datasta piileviä kaavoja ja rakenteita. Syväoppiminen on erityisen tehokas monimutkaisissa ja rakenteettomissa datakokonaisuuksissa, kuten kuvissa, tekstissä ja äänidatassa (Pani et al., 2021).

Konvoluutioverkot (Convolutional Neural Networks, CNN) ovat erikoistuneet kuvien ja visuaalisten tietojen analysointiin. CNN-verkkojen kyky tunnistaa visuaalisia piirteitä ja kuvioita tekee niistä erittäin hyödyllisiä tehtävissä, joissa data on kaksiulotteista, kuten kuvien tai videoiden analysoinnissa. Rekursiiviset neuroverkot (Recurrent Neural Networks, RNN) taas käsittelevät ajassa etenevää dataa, kuten tekstidataa tai aikarivien analysointia. RNN:t ovat erityisen hyödyllisiä silloin, kun halutaan analysoida dataa, jossa aikaisemmat tilat vaikuttavat nykyisiin ennusteisiin. Ne voivat analysoida suuria määriä dataa ja tarjota ennusteita monimutkaisissa, aikariippuvaisissa ympäristöissä. Pani et al. (2021) korostavat, että neuroverkkojen käyttö big data -analytiikassa on tullut yhä suositummaksi, koska ne tarjoavat mahdollisuuden analysoida valtavia määriä dataa ja tunnistaa erilaisia yhteyksiä ilman, että tarvitaan erityisiä malleja tai ohjelmointiohjeita.

2.2.4 Koneoppimisen työkalut

Koneoppiminen tarjoaa tehokkaita työkaluja mallintamiseen ja ennustamiseen suurten datamassojen analysoinnissa. Näiden työkalujen avulla yritykset voivat ennakoida tulevia tapahtumia, tehdä datalähtöisiä päätöksiä ja optimoida liiketoimintaprosessejaan.

Ennustuskyky perustuu mallien oppimiseen historiallisesta datasta ja kaavojen tunnistamiseen, mikä mahdollistaa esimerkiksi markkinatrendien, asiakaskäyttäytymisen ja resurssitarpeiden ennustamisen (Dandekar et al., 2024).

Ennakoivan analytiikan ohella koneoppiminen auttaa poikkeavuuksien tunnistamisessa, mikä on kriittistä esimerkiksi riskienhallinnassa ja laadunvalvonnassa. Poikkeavuudet ovat datapisteitä, jotka poikkeavat merkittävästi muusta datasta, ja niiden havaitsemiseen käytetään algoritmeja, kuten tukivektori-koneita (SVM) ja syväoppimismalleja. Nämä mallit ovat erityisen hyödyllisiä suurten ja monimutkaisten tietomassojen analysoinnissa, sillä ne pystyvät tunnistamaan piileviä ongelmia ja mahdollistavat nopeat reaktiot (Johri et al., 2023).

Koneoppimisen menestyksellä hyödyntäminen edellyttää kehittyneitä työkaluja ja kirjastoja, kuten TensorFlow, PyTorch ja Scikit-learn. TensorFlow on Googlen kehittämä avoimen lähdekoodin koneoppimiskehys, joka on suunniteltu erityisesti skaalautuviin, syväoppimista hyödyntäviin sovelluksiin. Se tarjoaa joustavan ympäristön syväoppimismallien rakentamiseen ja kouluttamiseen suurilla datamassoilla. Sen kyky hyödyntää GPU-laskentaa parantaa merkittävästi laskentatehoa ja tekee siitä erinomaisen vaihtoehdon suurten ja monimutkaisten neuroverkkojen käsittelyyn (Pani et al., 2021). PyTorch on toinen suosittu syväoppimiseen keskittyvä kirjasto, jota kehittää Meta (entinen Facebook). PyTorch tarjoaa helppokäyttöisen käyttöliittymän, joka on erityisesti suunniteltu tukemaan joustavuutta ja nopeaa prototypointia. Se on suosittu valinta tutkimuksessa ja akateemisessa maailmassa sen dynaamisen laskentakaavion ansiosta, mutta se soveltuu myös teollisiin sovelluksiin, joissa tarvitaan skaalautuvia ratkaisuja suurten datamassojen käsittelyyn. Scikit-learn on laajalti käytetty kirjasto erityisesti klassisten koneoppimisalgoritmien, kuten lineaarisen regression, päätöspuiden ja klusterointimenetelmien toteuttamiseen. Vaikka Scikit-learn ei ole suunniteltu syväoppimiseen samalla tavalla kuin TensorFlow tai PyTorch, se on erinomainen työkalu perinteisten koneoppimisratkaisujen nopeaan prototypointiin ja analysointiin. Scikit-learn on erityisen tehokas silloin, kun halutaan analysoida suuria, mutta rakenteellisesti yksinkertaisempia datamassoja.

2.2.5 Koneoppimisen sovelluskohteet

Koneoppimisen sovelluksia löytyy lähes kaikilta toimialoilta. Yksi yleisesti käytetyistä sovelluksista on markkinaennusteet, joissa koneoppimismallit analysoivat historiallista myyntidataa, talousindikaattoreita ja muita tärkeitä muuttujia, jotta voidaan ennustaa tulevia markkinatrendejä. Tämä mahdollistaa yrityksille kilpailuetua, kun ne voivat reagoida nopeammin markkinamuutoksiin ja optimoida varastonhallintaa tai tuotantoketjuja ennakoivasti. Toinen merkittävä sovellusalue on asiakaskäyttäytymisen ennustaminen. Koneoppimismallit voivat analysoida asiakkaiden ostotottumuksia, verkkokäyttäytymistä ja demografisia tietoja, jotta voidaan ennustaa, mitkä asiakkaat todennäköisesti ostavat tiettyjä tuotteita tai palveluita tulevaisuudessa (Johri et al., 2023). Dandekar et al. (2024) korostavat, että koneoppimisella on merkittävä rooli päätöksenteossa. Koneoppimismallit tarjoavat organisaatioille mahdollisuuden tehdä datalähtöisiä päätöksiä, jotka perustuvat tarkkoihin

ennusteisiin ja analyysiin. Tämä vähentää päätöksenteon riskejä ja auttaa yrityksiä optimoimaan toimintaansa tehokkaammin.

Anomaly Detection eli poikkeavuuksien tunnistaminen on kolmas keskeinen sovellusalue suurten datamassojen analysoinnissa. Poikkeavuuksia ovat datapisteet, jotka poikkeavat merkittävästi muista datan havaituista kaavoista. Näiden poikkeamien havaitseminen on tärkeää, koska ne voivat osoittaa ongelmia tai epätavallisia tapahtumia, jotka vaativat huomiota. Esimerkiksi poikkeuksien havaitseminen finanssidatassa voi ehkäistä petoksia, kun taas teollisuudessa se voi estää kalliita laitevaurioita. Koneoppimismalleja, kuten tukivektorikoneita (Support Vector Machines, SVM) ja syväoppimismalleja, käytetään laajasti poikkeavuuksien tunnistamiseen suurten datamassojen analysoinnissa. Nämä mallit pystyvät tunnistamaan monimutkaisia poikkeavuuksia ja reagoimaan nopeasti tilanteisiin, jotka vaativat välitöntä huomiota. Lisäksi ne voidaan optimoida käsittelemään suuria tietokokonaisuuksia hajautetuissa järjestelmissä, mikä parantaa niiden soveltuvuutta big data -ympäristöissä.

2.2.6 Käytännön esimerkit

Useat suuret yritykset ovat menestyksekkäästi hyödyntäneet koneoppimisen työkaluja ja kehyksiä suurten datamassojen analysoinnissa. Esimerkiksi Google käyttää laajasti TensorFlow'ta omissa tuotteissaan, kuten hakualgoritmeissaan ja mainonnan kohdentamisessa, analysoiden valtavia määriä käyttäjätietoa reaaliajassa. Tämä mahdollistaa tarkempia ennusteita käyttäjien toiminnasta ja parantaa liiketoimintatuloksia (Google Research, 2016.; Google Open Source, n.d.). Toinen esimerkki on Netflix, joka hyödyntää sekä TensorFlow'ta että PyTorchia kehittääkseen syväoppimismalleja suositusjärjestelmiensä parantamiseen. Netflixin algoritmit analysoivat käyttäjien katseluhistoriaa ja muita käyttäytymistietoja ennustaakseen, millaisia ohjelmia käyttäjät todennäköisesti haluaisivat katsoa seuraavaksi. Näiden koneoppimismallien avulla Netflix pystyy parantamaan asiakastytytyväisyyttä ja pidentämään käyttäjien palvelun käyttöaikaa (How Netflix Uses Python, 2023). Myös Amazon hyödyntää laajasti koneoppimista, erityisesti Amazon Web Services (AWS) -palvelualustansa kautta. AWS tarjoaa monia koneoppimiserätyksellisiä ratkaisuja yrityksille, jotka haluavat analysoida suuria datamassoja ja hyödyntää ennakoivaa analytiikkaa päätöksenteossaan. AWS:n tarjoamat koneoppimispalvelut, kuten Amazon

SageMaker, ovat auttaneet monia yrityksiä kehittämään koneoppimismalleja ilman tarvetta ylläpitää omaa infrastruktuuria (Amazon Web Services, 2023).

2.3 Yhteenveto

Tekoäly ja koneoppiminen mahdollistavat suurten datamassojen tehokkaan analysoinnin. Luvussa 2 on käyty läpi, miten nämä teknologiat tarjoavat ratkaisuja datan käsittelyn ja analysoinnin monimutkaisiin haasteisiin. Tekoälyn rooli datan käsittelyssä korostuu erityisesti, kun analysoidaan suuria määriä dataa, joka on heterogeenistä ja nopeasti muuttuvaa. Koneoppiminen tuo mukanaan skaalautuvia algoritmeja ja menetelmiä, jotka pystyvät löytämään piileviä kaavoja ja ennustamaan tulevia trendejä suurista ja monimutkaisista datamassoista. Luvussa korostettiin erityisesti, että koneoppiminen tarjoaa ennakoivan analytiikan ja poikkeavuuksien tunnistamisen kaltaisia työkaluja, jotka auttavat yrityksiä optimoimaan päätöksentekoaan. Ohjatut ja ohjaamattomat oppimismallit mahdollistavat datan tehokkaan luokittelun ja ennustamisen, kun taas syväoppimismallit, kuten konvoluutio- ja rekursiiviset neuroverkot, ovat osoittautuneet erinomaisiksi rakenteettoman datan, kuten kuvien ja tekstin, käsittelyssä. Koneoppimisen työkalut ja kehykset, kuten TensorFlow, PyTorch ja Scikit-learn, tarjoavat tehokkaita ratkaisuja mallien rakentamiseen ja toteuttamiseen suurissa dataympäristöissä. Näiden työkalujen käyttö on mahdollistanut merkittävät edistysaskeleet datan analysoinnissa.

Luvun sisällön pohjalta voidaan vastata tutkimuskysymykseen TK1: Millä tavoin tekoälyn ja koneoppimisen teknologioita voidaan soveltaa tehokkaasti suurten datamassojen analysointiin? Tekoälyä ja koneoppimista voidaan soveltaa tehokkaasti suurten datamassojen analysointiin hyödyntämällä skaalautuvia algoritmeja, kuten päätöspuita ja syväoppimista, sekä käyttämällä tehokkaita esikäsittelymenetelmiä datan puhdistamiseksi ja normalisoimiseksi. Lisäksi koneoppiminen tarjoaa työkaluja ennusteiden tekemiseen ja poikkeamien tunnistamiseen, mikä auttaa yrityksiä tekemään datalähtöisiä ja tarkkoja päätöksiä. Johtopäätöksenä voidaan todeta, että tekoäly ja koneoppiminen ovat välttämättömiä suurten datamassojen analysoinnissa ja ne tarjoavat ratkaisuja sekä teknologisiin että liiketoiminnallisiin haasteisiin, joita perinteiset analyysimenetelmät eivät pysty käsittelemään.

3 Tekoälyn hyödyntäminen kaupallisessa päätöksenteossa

Tekoälyn ja koneoppimisen nopea kehitys on alkanut muuttaa merkittävästi kaupallista päätöksentekoa suurissa yrityksissä. Näiden teknologioiden avulla yritykset voivat hyödyntää suuria määriä dataa tehokkaammin ja tehdä parempia, datalähtöisiä päätöksiä. Datalähtöinen päätöksenteko on noussut yhdeksi keskeiseksi tekijäksi nykypäivän liiketoimintaympäristössä, jossa kilpailu on kovaa ja yritykset tarvitsevat tarkkoja ja ajantasaisia tietoja päätöksentekonsa tueksi. Tekoäly ja koneoppiminen tarjoavat yrityksille kyvyn analysoida laajoja datamassoja, ennustaa tulevia tapahtumia ja optimoida liiketoimintaprosessejaan. Näiden teknologioiden avulla voidaan esimerkiksi analysoida asiakkaiden käyttäytymistä, tunnistaa markkinatrendejä ja tehostaa tuotantoketjuja. Johri et al. (2023) korostavat, että big data ja tekoäly ovat mullistamassa liiketoiminnan päätöksentekoa tarjoamalla yrityksille välineitä tehdä tarkempia ja nopeampia päätöksiä, mikä parantaa niiden kilpailukykyä globaaleilla markkinoilla. Tässä luvussa tarkastellaan tekoälyn ja koneoppimisen käytännön sovelluksia suurten yritysten päätöksenteossa sekä näiden teknologioiden tuomia kaupallisia hyötyjä ja haasteita.

3.1 Käytännön sovellukset päätöksenteossa

3.1.1 Markkinatrendien analyysi ja ennustaminen

Tekoäly ja koneoppiminen ovat muuttaneet merkittävästi tapoja, joilla suuryritykset analysoivat markkinatrendejä ja ennustavat tulevia liiketoiminnan suuntauksia. Näiden teknologioiden avulla yritykset voivat hyödyntää valtavia määriä dataa tunnistukseen kaavoja ja trendejä sekä ennustukseen tulevaisuuden markkinakehitystä. Tämä auttaa organisaatioita tekemään tarkempia ja nopeampia päätöksiä, mikä on erityisen tärkeää nykypäivän nopeasti muuttuvassa liiketoimintaympäristössä (Johri et al., 2023). Tekoälyä ja koneoppimista käytetään laajasti suurten markkinadata määrien analysoinnissa, sillä ne mahdollistavat datalähtöisen päätöksenteon automatisoinnin. Koneoppimismallit, kuten aikasarja-analyysi ja syväoppiminen, voivat analysoida historiallista markkinadataa, kuten myyntilukuja, talousindikaattoreita ja kuluttajakäyttäytymistä, ja tehdä ennusteita tulevista

suuntauksista. Tämä auttaa yrityksiä ennakoimaan markkinamuutoksia ja mukauttamaan liiketoimintastrategioitaan (Sun et al., 2022). Aikasarja-analyysi on yleisesti käytetty menetelmä markkinatrendien analysoinnissa. Se perustuu historiallisen datan analysointiin ja ennustaa tulevaa kehitystä aiemman suuntauksen perusteella. Yritykset voivat hyödyntää aikasarjamalleja ennustaakseen esimerkiksi myyntivolyymeja tai kysynnän vaihtelua kausiluonteisesti. Syväoppimismallit, kuten konvoluutio- ja rekursiiviset neuroverkot, soveltuvat monimutkaisten ja rakenteettomien tietojen analysointiin. Näitä malleja käytetään erityisesti silloin, kun analysoitava data on suurta ja sisältää esimerkiksi uutisia, sosiaalisen median sisältöä tai muita lähteitä, joista voidaan tunnistaa piileviä trendejä. Syväoppiminen on osoittautunut tehokkaaksi ennakoimaan markkinoiden kehitystä ja auttamaan yrityksiä sopeutumaan nopeasti muuttuviin tilanteisiin (Sun et al., 2022).

3.1.2 Asiakaskäyttäytymisen analyysi ja personointi

Sun et al. (2022) tuovat esiin esimerkin siitä, miten tekoälyä voidaan hyödyntää päätöksentekojärjestelmissä. Heidän tutkimuksensa osoittaa, kuinka yritykset voivat käyttää tekoälypohjaisia työkaluja analysoidakseen laajaa markkinadataa ja tunnistaa kuluttajakäyttäytymisen muutoksia ennakoivasti. Tällaiset työkalut tarjoavat yrityksille mahdollisuuden tehdä strategisia päätöksiä, jotka perustuvat datan analysointiin eikä pelkästään historiallisiin trendeihin. Esimerkiksi yritykset voivat käyttää näitä työkaluja optimoidakseen markkinointikampanjoitaan, parantaakseen asiakaskokemusta ja mukauttaakseen tuotteitaan nopeasti muuttuvien markkinatarpeiden mukaan (Sun et al., 2022). Tekoäly ja koneoppiminen ovat muuttaneet tapoja, joilla yritykset ymmärtävät ja ennakoivat asiakaskäyttäytymistä. Suurten datamassojen analysoinnin avulla koneoppimismallit voivat tunnistaa asiakaskäyttäytymisessä esiintyviä trendejä, minkä ansiosta yritykset voivat tehdä tarkkoja ja personoituja ratkaisuja markkinoinnissaan ja asiakaskokemuksen kehittämisessä. Koneoppimismallit auttavat yrityksiä jakamaan asiakaskunnan eri segmentteihin käyttäytymisen, taustatietojen ja ostotottumusten perusteella. Tämän asiakassegmentoinnin avulla markkinointiviestintä voidaan kohdistaa tarkemmin, mikä parantaa markkinoinnin tehokkuutta ja asiakastytyvääisyyttä. Personointi on toinen keskeinen koneoppimisen sovelluskohde, jossa yritykset voivat räätälöidä markkinointiviestejä ja tarjouksia yksittäisille asiakkaille. Koneoppimismallit analysoivat asiakaskäyttäytymistä, kuten selaushistoriaa, ostotottumuksia ja vuorovaikutuksia verkkosivustoilla, ja tarjoavat personoituja suosituksia asiakkaille heidän kiinnostuksensa

perusteella. Tämä parantaa asiakaskokemusta ja lisää todennäköisyyttä, että asiakkaat tekevät ostoksia tai jatkavat palveluiden käyttöä. Johri et al. (2023) mukaan tekoälypohjaiset asiakaskäyttäytymisen analyysityökalut auttavat yrityksiä ymmärtämään paremmin, mitä asiakkaat haluavat ja tarvitsevat. Tekoäly voi esimerkiksi analysoida asiakkaiden vuorovaikutusta sosiaalisen median kanssa, tunnistaa heidän kiinnostuksen kohteitaan ja tarjota personoituja suosituksia reaaliajassa. Tämä parantaa asiakastytyvyyttä ja edistää asiakasuskollisuutta.

Ennakoiva analytiikka on keskeinen työkalu, jonka avulla yritykset voivat ennustaa asiakkaiden tarpeita ja reagoida niihin etukäteen. Tämä voi sisältää esimerkiksi asiakkaiden ostokäyttäytymisen ennustamisen, asiakkaiden elinkaaren arvon laskemisen tai asiakaspoistuman ennustamisen (Johri et al., 2023). Ennakoivan analytiikan avulla yritykset voivat kehittää tehokkaampia asiakasstrategioita ja parantaa asiakaskokemusta. Suosittelujärjestelmät ovat yksi konkreettinen esimerkki ennakoivasta analytiikasta, joka parantaa asiakaskokemusta. Suosittelujärjestelmät analysoivat asiakkaiden ostotietoja, selauskäyttäytymistä ja aikaisempia vuorovaikutuksia tarjotakseen personoituja tuote- tai palvelusuosituksia. Tämä ei ainoastaan paranna asiakaskokemusta, vaan lisää myös myyntiä ja asiakasuskollisuutta (Johri et al., 2023). Toinen tärkeä sovellusalue on asiakaspoistuman ennustaminen. Asiakaspoistuma tarkoittaa sitä, kun asiakas lopettaa palvelun käytön tai siirtyy kilpailijan asiakkaaksi. Koneoppimismallit voivat analysoida asiakkaiden käyttäytymistä ja tunnistaa poikkeamia, jotka voivat viitata mahdolliseen asiakaspoistumaan. Tällöin yritys voi puuttua asiaan ennakoivasti tarjoamalla kohdennettuja kampanjoita tai erityisiä alennuksia, jotka kannustavat asiakkaita pysymään palvelun käyttäjinä. Ennakoiva analytiikka antaa yrityksille mahdollisuuden toimia proaktiivisesti ja varmistaa, että asiakkaat saavat parhaan mahdollisen kokemuksen heidän tarpeidensa ja käyttäytymisensä perusteella.

3.1.3 Resurssien optimointi ja -hallinta

Tekoäly ja koneoppiminen ovat mullistaneet suurten yritysten resurssien optimoinnin ja toimitusketjun hallinnan. Näiden teknologioiden avulla yritykset voivat analysoida suuria määriä logistiikkaan, varastointiin ja tuotantoon liittyvää dataa ja tehdä nopeita, datalähtöisiä päätöksiä. Tämä parantaa toimitusketjujen tehokkuutta ja mahdollistaa resurssien paremman hallinnan. Tekoälyn ja koneoppimisen soveltaminen logistiikassa ja varastonhallinnassa

auttaa yrityksiä ennakoimaan tulevia tarpeita ja optimoimaan toimitusketjuja. Algoritmien avulla yritykset voivat analysoida kysyntäennusteita, varastotasoja ja toimitusaikoja sekä optimoida varastohallintaa ja logistiikkareittejä. Tämä vähentää ylikapasiteettia ja alikapasiteettia, mikä vähentää varastointikustannuksia ja parantaa toimitusnopeutta.

Esimerkiksi koneoppimismalleja voidaan käyttää ennakoimaan varastotarpeita analysoimalla historiallista myyntidataa ja ulkoisia tekijöitä, kuten kausiluonteisuutta ja markkinatrendejä. Tämä mahdollistaa yrityksille paremman varastohallinnan, jolloin tuotteita on saatavilla oikeassa paikassa ja oikeaan aikaan. Pani et al. (2021) korostavat, että pilvipalveluihin yhdistetyt koneoppimismallit tarjoavat skaalautuvan ratkaisun, joka mahdollistaa reaaliaikaisen varastohallinnan, optimoidut toimitusreitit ja parantuneen toimitusketjun tehokkuuden. Toimitusketjujen tehostaminen on erityisen tärkeää globaalisti toimiville yrityksille, jotka käsittelevät valtavia määriä tuotteita ja tietoa useissa eri maissa. Tekoälyn avulla yritykset voivat optimoida logistiikkansa, vähentää viivästyksiä ja parantaa toimitusvarmuutta. Tämä johtaa myös parempaan asiakaskokemukseen ja kustannussäästöihin.

Reaaliaikainen data-analyysi on toinen merkittävä tekoälyn sovellus toimitusketjun hallinnassa. Reaaliaikainen analyysi mahdollistaa yrityksille nopean reagoinnin toimitusketjun häiriöihin ja nopeuttaa päätöksentekoa tuotannon ja logistiikan hallinnassa. Koneoppimismallit voivat analysoida sensoreiden keräämää dataa tuotantolinjoilta, varastoista ja logistiikasta, ja tarjota reaaliaikaisia suosituksia esimerkiksi kysyntämuutoksiin reagoimiseksi tai logististen reittien optimointiin. Esimerkiksi monissa teollisuusyrityksissä tekoälyä käytetään tuotannon suunnittelussa ja huoltojen ennustamisessa. Koneoppimismallit voivat analysoida koneiden toiminnasta saatavaa reaaliaikaista dataa ja ennustaa, milloin laitteiden huolto on tarpeen. Tämä vähentää suunnittelemattomia seisokkeja ja parantaa tuotannon tehokkuutta. Samalla tavalla tekoälyä voidaan käyttää optimoimaan logistiikkareittejä muuttuvien sääolosuhteiden tai toimitusviiveiden perusteella. Toinen tärkeä tekoälyn sovellusalue on kysynnän ennustaminen reaaliaikaisen datan avulla. Yritykset voivat analysoida myyntiä ja asiakaskäyttäytymistä reaaliaikaisesti ja sopeuttaa tuotantoaan ja logistiikkaansa vastaamaan muuttuviin kysyntätilanteisiin. Tekoälypohjaiset ratkaisut voivat ennakoida äkilliset muutokset markkinakysynnässä ja antaa yrityksille mahdollisuuden reagoida nopeasti ennen kuin varastoihin syntyy puutteita tai ylitarjontaa (Sun et al., 2022).

3.1.4 Riskienhallinta ja petosten havaitseminen

Tekoälyn ja koneoppimisen käyttö liiketoiminnan riskienhallinnassa ja petosten havaitsemisessa on kasvanut merkittävästi. Nämä teknologiat auttavat yrityksiä tunnistamaan riskejä ja ongelmia ennakoivasti analysoimalla valtavia määriä dataa, mikä mahdollistaa nopean reagoinnin ja tehokkaamman riskienhallinnan. Lisäksi koneoppimismallit voivat tunnistaa poikkeamia ja epätavallisia toimintoja, mikä auttaa estämään petoksia ja vähentämään taloudellisia menetyksiä. Tekoälyn ja koneoppimisen avulla yritykset voivat analysoida valtavia määriä liiketoimintadataa ja tunnistaa piileviä riskejä, jotka saattavat uhata niiden toimintaa. Koneoppimismallit pystyvät analysoimaan erilaisia riskitekijöitä, kuten taloudellisia indikaattoreita, markkinatrendejä ja sisäisiä toimintoja, ja antavat yrityksille mahdollisuuden ennakoida ongelmia ennen kuin ne eskaloituvat. Esimerkiksi neuroverkkoja käytetään laajasti riskianalyyseissä, sillä ne voivat tunnistaa monimutkaisia yhteyksiä ja ennustaa tulevia riskejä (Jamalpur et al., 2024). Jamalpur et al. (2024) tuovat esiin, että neuroverkkoihin perustuvat tekoälymallit ovat erityisen tehokkaita tunnistamaan liiketoimintariskejä, kuten taloudellisia kriisejä, markkinamuutoksia ja operatiivisia haasteita. Näitä malleja voidaan käyttää sekä sisäisiin että ulkoisiin riskitekijöihin. Sisäisissä riskianalyyseissä tekoäly voi auttaa tunnistamaan esimerkiksi resurssien epätasaisen käytön tai tuotantoprosessien pullonkauloja. Ulkoisiin riskeihin tekoäly voi puolestaan reagoida analysoimalla markkinoiden kehitystä, kilpailijoiden toimia tai geopolitiittisiä muutoksia. Riskianalyysin lisäksi tekoälyä voidaan käyttää ennustamaan toimitusketjun häiriöitä ja suunnittelemaan varautumistoimenpiteitä mahdollisia häiriöitä vastaan. Reaaliaikainen data-analyysi auttaa yrityksiä tunnistamaan häiriöiden todennäköisyyksiä ja suunnittelemaan varautumistoimia, mikä voi vähentää kustannuksia ja estää vakavia liiketoimintahäiriöitä.

3.1.5 Strategisen päätöksenteon tukeminen

Tekoälyn ja koneoppimisen rooli ei rajoitu vain operatiiviseen toimintaan ja analytiikkaan; ne tarjoavat myös tehokkaita työkaluja strategisen päätöksenteon tueksi ylimmälle johdolle. Nykyään yritykset käyttävät tekoälyä laajasti strategisen suunnittelun ja riskien arvioinnin tueksi, mikä mahdollistaa paremmin informoidut päätökset liiketoiminnan suunnasta. Tekoälyn hyödyntäminen tukee ylimmän johdon strategista päätöksentekoa tarjoamalla reaaliaikaisia tietoja ja analytiikkaa, joilla voidaan vaikuttaa pitkän aikavälin päätöksiin. Koneoppimismallit analysoivat suuria määriä historiallista ja reaaliaikaista dataa ja tarjoavat johdolle näkemyksiä, jotka voivat auttaa tunnistamaan mahdollisuuksia ja uhkia

liiketoimintaympäristössä. Tämä tietoon perustuva lähestymistapa varmistaa, että päätökset tehdään objektiivisesti ja datan tukemina, mikä vähentää inhimillisen virheen riskiä ja parantaa ennustettavuutta (Sun et al., 2022).

Sun et al. (2022) mukaan tekoälypohjaisten päätöksenteon tukijärjestelmien (Decision Support Systems, DSS) avulla ylimmälle johdolle voidaan tarjota tehokkaita työkaluja strategisen suunnittelun tueksi. Näiden järjestelmien avulla johto voi tarkastella eri vaihtoehtoja, vertailla skenaarioita ja simuloida päätöksien vaikutuksia yrityksen tulevaan kehitykseen. Simuloinnit tarjoavat yrityksille mahdollisuuden kokeilla erilaisia strategisia vaihtoehtoja ja arvioida niiden vaikutuksia ennen kuin päätöksiä tehdään. Tämä antaa ylimmälle johdolle paremman käsityksen siitä, miten erilaiset päätökset voivat vaikuttaa liiketoimintaan pitkällä aikavälillä (Jamalpur et al., 2024). Koneoppimismallit mahdollistavat erilaisten skenaarioiden simuloinnin esimerkiksi markkinamuutosten, sääolosuhteiden, kilpailijoiden toimien tai geopoliittisten tapahtumien vaikutuksista liiketoimintaan. Tämä antaa yrityksille mahdollisuuden varautua paremmin ennakoimattomiin tilanteisiin ja suunnitella strategioita, jotka perustuvat realistisiin ja tietoon perustuviin skenaarioihin. Näin tekoäly toimii arvokkaana työkaluna riskien hallinnassa ja strategisessa suunnittelussa (Sun et al., 2022). Esimerkiksi suurilla teollisuusyrityksillä, jotka toimivat useilla eri markkinoilla, tekoäly voi auttaa arvioimaan, miten erilaiset taloudelliset tai poliittiset skenaariot vaikuttavat niiden toimintaan eri alueilla. Tämän tiedon perusteella yritykset voivat laatia skenaariopohjaisia toimintasuunnitelmia ja varautua muutoksiin etukäteen. Tekoäly auttaa myös minimoimaan riskejä ja parantamaan päätöksenteon laatua, kun yritykset voivat kokeilla erilaisia strategioita ilman merkittäviä kustannuksia.

3.2 Kaupalliset hyödyt ja haasteet

3.2.1 Tekoälyn tuomat tehokkuusparannukset

Tekoälyn ja koneoppimisen avulla yritykset voivat automatisoida monia liiketoimintaprosessejaan, mikä johtaa huomattaviin tehokkuusparannuksiin ja kustannussäästöihin. Koneoppimismallit analysoivat ja optimoivat prosesseja reaaliajassa, mikä vähentää manuaalista työtä ja minimoi virheet. Esimerkiksi tuotantoprosessien ja logistiikan optimointi tekoälyn avulla voi vähentää kustannuksia, parantaa toimitusketjujen toimintaa ja lisätä tuotantokapasiteettia ilman lisäresursseja (Dandekar et al., 2024). Dandekar et al. (2024) korostavat, että big data -analytiikan implementointi on erityisen hyödyllistä yrityksille, jotka käsittelevät suuria tietomassoja, kuten vähittäiskaupat, logistiikka-alan yritykset ja valmistajat. Prosessien automatisoinnilla ja resurssien optimoinnilla voidaan saavuttaa merkittäviä kustannussäästöjä, koska tekoäly voi tunnistaa datasta tehokkuuden pullonkauloja ja ehdottaa optimaalisia ratkaisuja niiden korjaamiseksi. Tämä vähentää ylikapasiteettia ja parantaa resurssien käyttöä, mikä johtaa suoriin taloudellisiin hyötyihin.

3.2.2 Kilpailuedun saavuttaminen tekoälyn avulla

Tekoälyä hyödyntävät yritykset voivat saavuttaa merkittävää kilpailuetua verrattuna niihin, jotka eivät hyödynnä tätä teknologiaa. Tekoälyllä voidaan tehdä tarkempia ennusteita, analysoida markkinatrendejä ja ymmärtää asiakaskäyttäytymistä tehokkaammin, mikä antaa yrityksille paremman kyvyn reagoida nopeasti muuttuviin markkinaolosuhteisiin. Tämä erottuu erityisesti markkinoilla, joilla kilpailu on kovaa ja joissa yritysten on jatkuvasti innovoitava ja sopeuduttava (Johri et al., 2023). Johri et al. (2023) korostavat, että tekoälyn hyödyntäminen liiketoiminnan päätöksenteossa ja analytiikassa antaa yrityksille kyvyn erottautua kilpailijoistaan. Yritykset, jotka pystyvät hyödyntämään tekoälyä tehokkaasti, voivat tehdä nopeampia ja tarkempia päätöksiä, tunnistaa markkinamahdollisuuksia ennen kilpailijoitaan ja tarjota personoituja ratkaisuja asiakkailleen. Tämä mahdollistaa paremman asiakaskokemuksen ja vahvistaa asiakasuskollisuutta, mikä lisää yritysten kilpailukykyä pitkällä aikavälillä. Tekoälyyn perustuva päätöksenteko vähentää inhimillisten virheiden ja subjektiivisuuden riskejä, mikä parantaa päätöksenteon laatua. Datalähtöinen päätöksenteko perustuu tekoälyn analysoimaan objektiiviseen tietoon, mikä mahdollistaa faktapohjaisten ja tarkkojen päätösten tekemisen. Tämä on erityisen tärkeää, kun tehdään strategisia päätöksiä,

joilla on suuri vaikutus yrityksen pitkän aikavälin menestykseen. Tekoälypohjaiset päätöksenteon tukijärjestelmät auttavat vähentämään päätöksenteon subjektiivisuutta ja inhimillisiä harhoja. Koneoppimismallit voivat analysoida suuria määriä historiallista ja reaaliaikaista dataa, mikä mahdollistaa paremmin perustellut päätökset. Tämä vähentää epävarmuutta ja parantaa päätöksenteon tarkkuutta, mikä auttaa yrityksiä tekemään kestävämpiä ja riskittömämpiä ratkaisuja.

3.2.3 Teknologiset haasteet ja legacy-järjestelmät

Vaikka tekoäly ja koneoppiminen tarjoavat merkittäviä kaupallisia hyötyjä, niiden käyttöönotto ja hyödyntäminen eivät tule ilman haasteita. Teknologiset rajoitteet, henkilöstön osaamisen puute, eettiset ja juridiset kysymykset sekä organisaatiokulttuurin muutos voivat olla merkittäviä esteitä tekoälyn implementoinnissa suurissa yrityksissä (Dandekar ym., 2024). Yksi merkittävimmistä teknologisista haasteista tekoälyn käyttöönotossa suurissa yrityksissä on sen integroiminen olemassa oleviin, usein vanhentuneisiin, tietojärjestelmiin. Nämä niin sanotut legacy-järjestelmät ovat monesti kriittisiä yrityksen päivittäiselle toiminnalle, ja niiden korvaaminen tai päivittäminen voi olla monimutkaista ja kallista. Legacy-järjestelmät eivät ole alun perin suunniteltu tukemaan moderneja tekoäly- ja koneoppimISRatkaisuja, mikä aiheuttaa merkittäviä teknisiä haasteita (Kirola ym., 2023). Ensinnäkin teknologiset yhteensopivuusongelmat ovat yleisiä. Legacy-järjestelmät saattavat käyttää vanhoja ohjelmointikieliä, tietokantaratkaisuja ja infrastruktuureja, jotka eivät ole yhteensopivia uusien tekoälypohjaisten sovellusten kanssa. Tämä vaikeuttaa tiedon jakamista ja datan integrointia, mikä on kriittistä tekoälyjärjestelmien toiminnalle. Esimerkiksi reaaliaikainen datan analysointi ja päätöksenteko edellyttävät, että tekoälyratkaisut pääsevät käsiksi ajantasaiseen dataan, mikä voi olla haastavaa vanhoissa järjestelmissä. Toiseksi tietoturva- ja tietosuoja-asiat korostuvat integraatiossa. Kun tekoälyratkaisuja yhdistetään olemassa oleviin järjestelmiin, on varmistettava, että tietoturvastandardit täyttyvät ja että arkaluonteinen data on suojattu (Dandekar ym., 2024). Legacy-järjestelmät eivät välttämättä noudata nykyisiä tietoturvakäytäntöjä, mikä voi altistaa yrityksen riskeille. Tämä edellyttää usein järjestelmien perusteellista arviointia ja mahdollisia päivityksiä, jotta ne täyttävät nykyiset tietoturvavaatimukset. Kolmanneksi organisatoriset haasteet, kuten henkilöstön vastarinta ja muutosjohtaminen, voivat hidastaa integraatioprosessia. Henkilöstö saattaa olla tottunut käyttämään tiettyjä järjestelmiä ja työtapoja, ja uusien tekoälyratkaisujen käyttöönotto voi aiheuttaa epävarmuutta tai muutosvastarintaa. On tärkeää kommunikoida

muutoksen syyt ja hyödyt selkeästi sekä tarjota tarvittavaa koulutusta ja tukea henkilöstölle (Dandekar ym., 2024). Lisäksi taloudelliset tekijät ovat merkittävä este. Integraatio voi vaatia merkittäviä investointeja niin laitteistojen, ohjelmistojen kuin osaamisenkin osalta. Yritysten on usein päivitettävä infrastruktuuriaan, hankittava uusia teknologioita ja mahdollisesti palkattava ulkopuolisia asiantuntijoita toteuttamaan integraation. Nämä kustannukset voivat olla huomattavia, erityisesti jos yrityksen järjestelmät ovat hyvin vanhentuneita. Yhteenvetona voidaan todeta, että tekoälyn integroiminen olemassa oleviin järjestelmiin on monimutkainen prosessi, joka vaatii huolellista suunnittelua, resursseja ja muutosjohtamista. Yritysten on kehitettävä strategioita, jotka mahdollistavat sujuvan integraation minimoiden liiketoiminnan häiriöt ja maksimoiden uuden teknologian tuomat hyödyt (Dandekar ym., 2024).

3.2.4 Infrastruktuurivaatimukset ja ympäristövaikutukset

Tekoälyratkaisujen implementointi, erityisesti kun käsitellään suuria tietomassoja, vaatii huomattavia laskentaresursseja. Koneoppimismallit, kuten syväoppimisen neuroverkot, voivat sisältää miljoonia parametreja, jotka on opetettava suurilla datamäärillä. Tämä opetustyö vaatii suurta laskentatehoa, mikä tarkoittaa tehokkaita prosessoreita, kuten GPU- tai TPU-pohjaisia järjestelmiä (Kirola ym., 2023). Lisäksi tekoälyn jatkuva käyttö tuotantoympäristössä edellyttää huomattavaa laskentatehoa reaaliaikaisen datan käsittelyyn. Tämä voi johtaa korkeisiin käyttökustannuksiin, erityisesti jos käytetään pilvipalveluita, joissa laskentatehosta maksetaan käytön mukaan. Myös tallennuskapasiteetin tarve kasvaa merkittävästi. Suuret datamassat vaativat paljon tallennustilaa, ja datan täytyy olla nopeasti saatavilla analysointia varten. Tämä voi tarkoittaa investointeja uusiin tallennusratkaisuihin, kuten nopeisiin SSD-levyihin tai hajautettuihin tietovarastoihin. Lisäksi datan varmuuskopiointi ja palautusjärjestelmät on päivitettävä vastaamaan kasvavaa tallennustarvetta ja tietoturva-vaatimuksia. Verkkoinfrastruktuurin kapasiteetti on myös kriittinen tekijä. Suurten datamassojen siirtäminen ja käsittely edellyttävät nopeita ja luotettavia verkkoyhteyksiä. Tämä voi tarkoittaa investointeja nopeampiin verkkolaitteisiin ja -yhteyksiin sekä verkon suorituskyvyn optimointiin. Ilman riittävää verkkokapasiteettia datan käsittely voi hidastua merkittävästi, mikä vaikuttaa tekoälyratkaisujen tehokkuuteen (Dandekar ym., 2024). Lisäksi on huomioitava energiatehokkuus ja ympäristövaikutukset. Suuret laskentakeskukset kuluttavat paljon energiaa, mikä lisää operatiivisia kustannuksia ja ympäristökuormitusta. Yritysten onkin pohdittava kestävä kehityksen periaatteita ja mahdollisuuksia hyödyntää energiatehokkaita ratkaisuja tai uusiutuvaa energiaa.

3.2.5 Tekoälyn käyttöönoton haasteet ja strategiat

Tekoälyn ja koneoppimisen tehokas hyödyntäminen vaatii erityisosaamista, joka voi olla rajallisesti saatavilla organisaatioissa. Data-analyytikoista, datatieteilijöistä ja koneoppimisen insinööreistä on maailmanlaajuinen pula, mikä tekee rekrytoinnista haastavaa ja nostaa palkkakustannuksia (Dandekar ym., 2024). Lisäksi henkilöstö ei usein omaa tarvittavia taitoja tekoälyratkaisujen kehittämiseen tai käyttämiseen, mikä edellyttää merkittäviä investointeja koulutukseen. Tämä koskee sekä teknistä henkilöstöä että liiketoimintajohtajia, joiden on ymmärrettävä tekoälyn mahdollisuudet ja rajoitukset informoitujen päätösten tekemiseksi (Kirola ym., 2023).

Tekoälyratkaisujen käyttöönotto vaatii organisaatiolta kulttuurisia muutoksia ja vahvaa muutosjohtamista. Johdon sitoutuminen on ratkaisevaa, jotta uudet teknologiat voidaan integroida toimintaan ja työntekijät voivat omaksua uudet prosessit sujuvasti. Työntekijöiden pelot työpaikkojen menetyksestä tai työnkuvien muuttumisesta voivat johtaa vastarintaan, mikä korostaa avoimen viestinnän ja koulutuksen merkitystä. Jamalpur et al. (2024) painottavat, että henkilöstön pelkojen käsittely ja muutoksen hallinta ovat keskeisiä haasteita tekoälyn implementoinnissa. Näiden voittaminen vaatii suunnitelmallista ja johdonmukaista lähestymistapaa.

Tekoälyn käyttöönoton onnistumiseksi yritysten on hyödynnettävä vaiheittaista implementointia, kumppanuuksia ja jatkuvaa osaamisen kehittämistä. Vaiheittainen implementointi, jossa tekoälyratkaisut otetaan käyttöön pilottiprojektien avulla, auttaa vähentämään teknologisia riskejä ja hallitsemaan kustannuksia. Tämä lähestymistapa mahdollistaa teknologioiden testaamisen ja hienosäätämisen ennen laajempaa käyttöönottoa (Kirola et al., 2023).

Monilla organisaatioilla ei ole riittävää sisäistä osaamista tekoälyn käyttöönottoon, joten strategiset kumppanuudet ulkopuolisten asiantuntijoiden tai konsultointiyritysten kanssa voivat olla ratkaisu. Ulkoistamalla tekoälyratkaisujen suunnittelun ja toteutuksen yritykset voivat hyödyntää uusimpia teknologioita ja parhaita käytäntöjä, mikä nopeuttaa käyttöönottoa ja auttaa selviämään teknologisista sekä lainsäädännöllisistä haasteista (Sun et al., 2022).

Koulutus ja osaamisen kehittäminen ovat ratkaisevia tekoälyn pitkäjänteisen hyödyntämisen kannalta. Teknologian jatkuva kehitys vaatii henkilöstöltä jatkuvaa oppimista, mikä edellyttää investointeja osaamisen kehittämiseen kaikilla organisaation tasoilla. Tämä kattaa niin teknisten taitojen kuin johtamistaitojen kehittämisen, jotta organisaation johto voi ohjata tekoälypohjaisia strategioita tehokkaasti (Dandekar ym., 2024). Investoimalla koulutukseen yritykset voivat varmistaa, että niiden henkilöstö pystyy hyödyntämään tekoälyratkaisuja täysimääräisesti ja mukautumaan teknologian nopeaan kehitykseen.

3.2.6 Eettisyys ja Tietosuoja

Tekoälyn käyttö herättää merkittäviä eettisiä ja tietosuojaan liittyviä kysymyksiä, jotka yritysten on huomioitava. Keskeistä on luoda selkeitä eettisiä periaatteita ja ohjeistuksia, jotka varmistavat, että tekoälyratkaisut ovat reiluja, läpinäkyviä ja lainsäädännön mukaisia. Tämä sisältää henkilötietojen käsittelyn sääntöjenmukaisuuden, syrjinnän ja harhojen välttämisen sekä mallien selitettävyyden kehittämisen. Erityisesti GDPR-säädökset Euroopassa asettavat tiukat rajat henkilötietojen keräämiselle ja käytölle, mikä voi lisätä monimutkaisuutta tekoälyn käyttöönnotossa. Tietosuojakysymykset ja tekoälymallien "mustan laatikon" ongelma ovat merkittäviä haasteita. Monimutkaiset koneoppimismallit, kuten syväoppiminen, voivat olla vaikeita ymmärtää ja selittää, mikä voi johtaa luottamuspulaan asiakkaiden ja sidosryhmien keskuudessa. Läpinäkyvyyden rakentaminen on avainasemassa luottamuksen vahvistamisessa, ja tässä Explainable AI (XAI) -menetelmät voivat auttaa tekemään tekoälymallien päätöksistä ymmärrettäviä. Dandekar et al. (2024) ja Jamalpur et al. (2024) korostavat dataetiikan ja läpinäkyvyyden merkitystä tekoälyn hyödyntämisessä. Yritysten tulee luoda käytännöt, jotka ovat ymmärrettäviä ja helposti sovellettavissa kaikilla organisaation tasoilla. Läpinäkyvien prosessien avulla voidaan paitsi vähentää tekoälyn väärinkäytöstä johtuvia riskejä myös rakentaa luottamusta niin yrityksen sisällä kuin ulkopuolella.

3.3 Yhteenveto

Luku 3 tarkasteli sitä, miten tekoäly ja koneoppiminen ovat merkittävästi muuttaneet suurten yritysten kaupallista päätöksentekoa. Tärkeimmät havainnot osoittavat, että tekoäly auttaa yrityksiä tekemään tehokkaampia ja dataan perustuvia päätöksiä, jotka parantavat

kilpailukykyä, vähentävät kustannuksia ja lisäävät kaupallisen päätöksenteon tarkkuutta. Tekoälyratkaisujen avulla yritykset voivat esimerkiksi analysoida markkinatrendejä, optimoida toimitusketjuja, ennakoida asiakaskäyttäytymistä ja hallita riskejä reaaliaikaisen datan pohjalta. Tutkimuskysymys TK2: "Kuinka tekoälyä ja koneoppimista voidaan hyödyntää suurten yritysten kaupallisen päätöksenteon tukena?" sai vastauksia luvun 3 analyysistä. Tekoäly auttaa suuria yrityksiä optimoimaan resurssejaan, tehostamaan liiketoimintaprosessejaan ja tarjoamaan parempia asiakaskokemuksia ennakoivan analytiikan avulla. Lisäksi tekoälypohjaiset ratkaisut auttavat yrityksiä tekemään tarkempia strategisia päätöksiä simulaatioiden ja datan analysoinnin kautta, mikä vahvistaa päätöksenteon laatua ja vähentää riskejä sekä turhia kuluja. Keskeiset johtopäätökset viittaavat siihen, että tekoälyn avulla voidaan parantaa päätöksenteon nopeutta ja tarkkuutta, mikä on erityisen arvokasta yrityksille, jotka toimivat nopeasti muuttuvissa markkinaolosuhteissa. Yritykset, jotka hyödyntävät tekoälyä, voivat myös saavuttaa kilpailuetua ja erottua markkinoilla, sillä tekoäly mahdollistaa paremman kyvyn ennakoida tulevia liiketoimintaympäristön muutoksia ja asiakastarpeita.

4 Yhteenveto

Tässä kirjallisuuskatsauksessa on tarkasteltu tekoälyn ja koneoppimisen roolia suurten datamassojen analysoinnissa sekä niiden vaikutusta suurten yritysten kaupalliseen päätöksentekoon. Keskeiset havainnot osoittavat, että tekoäly ja koneoppiminen mahdollistavat suurten datamassojen tehokkaan käsittelyn ja tukevat strategista päätöksentekoa tarjoamalla syvällisiä analyysseja ja ennusteita. Nämä teknologiat helpottavat datan automaattista esikäsittelyä, analysointia ja hyödyntämistä liiketoiminnassa. Esimerkiksi neuroverkkojen avulla yritykset voivat simuloida erilaisia liiketoimintaskenaarioita ja arvioida niiden vaikutuksia (Jamalpur ym., 2024). Lisäksi tekoälypohjaiset päätöksenteon tukijärjestelmät optimoivat resurssien käyttöä ja vähentävät liiketoimintariskejä (Sun ym., 2022).

Tekoäly nopeuttaa päätöksentekoa analysoimalla suuria datamassoja reaaliaikaisesti, mikä mahdollistaa tarkemmat ja ajantasaiset päätökset. Johri ym. (2023) ovat havainneet, että tekoälyn hyödyntäminen liiketoiminnassa vähentää inhimillisiä virheitä ja parantaa operatiivista tehokkuutta. Ennakoivan analytiikan avulla yritykset voivat ennustaa markkinatrendejä ja asiakaskäyttäytymistä, mikä tukee strategista päätöksentekoa ja resurssien optimointia. Lisäksi tekoäly auttaa tunnistamaan ja hallitsemaan poikkeamia, kuten epätavallisia tapahtumia, suurissa datamassoissa, mikä parantaa riskienhallintaa ja reagointikykyä.

Tekoälyn ja koneoppimisen hyödyntäminen vaatii kuitenkin merkittäviä investointeja infrastruktuuriin, laskentatehoihin ja henkilöstön osaamiseen. Kirola ym. (2023) korostavat rinnakkaisprosessoinnin ja hajautettujen tietokantojen merkitystä suurten datamassojen käsittelyssä. Samalla henkilöstön teknologiaosaamisen puute on merkittävä este tekoälyn tehokkaalle käyttöönotolle. Yritysten on panostettava jatkuvaan koulutukseen ja tarjottava työntekijöille mahdollisuuksia oppia esimerkiksi TensorFlow'n ja PyTorchin kaltaisten työkalujen käyttöä.

Tietosuoja, dataetiikka ja lainsäädäntö muodostavat myös merkittäviä haasteita. Dandekar ym. (2024) painottavat, että yritysten tulee noudattaa tiukkoja eettisiä standardeja ja varmistaa

toimintansa lainsäädännön mukaisuus. Tämä auttaa vahvistamaan asiakkaiden luottamusta ja välttämään mahdollisia juridisia ongelmia.

Tekoäly ja koneoppiminen ovat korvaamattomia teknologioita nykyaikaisessa liiketoiminnassa, mutta niiden menestyksellä implementointi edellyttää strategista ja vastuullista lähestymistapaa. Yritysten tulisi panostaa jatkuvaan koulutukseen, sillä henkilöstön teknologiaosaamisen kehittäminen on avainasemassa. On tärkeää järjestää säännöllistä koulutusta ja luoda oppimisohjelmia, jotka keskittyvät tekoälyn ja koneoppimisen työkalujen, kuten TensorFlow'n ja PyTorchin, tehokkaaseen käyttöön. Samalla yhteistyön edistäminen on olennaista. Yritysten kannattaa osallistua tekoälyekosysteemeihin, kuten tutkimusohjelmiin ja startup-kumppanuuksiin, sillä tämä voi nopeuttaa innovaatioiden kehitystä ja tuoda käyttöön uusia ratkaisuja.

Tietosuoja ja eettisyys tulee asettaa etusijalle. Yritysten on kehitettävä selkeät ohjeet dataetiikasta ja varmistettava, että tekoälyä käytetään vastuullisesti ja läpinäkyvästi. Tämä ei ainoastaan vähennä mahdollisia riskejä, vaan myös vahvistaa yrityksen mainetta ja sidosryhmien luottamusta. Lisäksi investoinnit skaalautuviin teknologioihin, kuten pilvipalveluihin AWS:n, Google Cloud AI:n ja Azure Machine Learning:n kautta, ovat välttämättömiä. Tällaiset palvelut tarjoavat kustannustehokkaita ratkaisuja tekoälyn hyödyntämiseen suurissa datamassoissa ja helpottavat teknologian käyttöönottoa.

Yritysten tulisi jatkossa keskittyä tekoälyn ja koneoppimisen hyödyntämiseen uusilla liiketoiminta-alueilla, kuten kestävässä kehityksessä ja asiakaskokemuksen parantamisessa. Teknologian kehitys, kuten generatiivinen tekoäly ja multimodaaliset mallit, tarjoaa myös uusia mahdollisuuksia, joita yritysten kannattaa tutkia ja testata. Lopuksi on tärkeää huomata, että tekoäly ja koneoppiminen eivät ole vain teknologisia työkaluja, vaan strategisia investointeja, jotka voivat muuttaa yritysten toimintatapoja ja parantaa niiden kilpailukykyä. Vastuullisesti ja pitkäjänteisesti käytettynä ne tarjoavat merkittävää arvoa niin yrityksille kuin niiden asiakkaille.

Lähteet

1. M. Kirola, M. Memoria, M. Shuaib, K. Joshi, S. Alam and F. Alshanketi, "A Referenced Framework on New Challenges and Cutting-Edge Research Trends for Big-Data Processing Using Machine Learning Approaches," 2023 International Conference on Smart Computing and Application (ICSCA), Hail, Saudi Arabia, 2023, pp. 1-5, doi: 10.1109/ICSCA57840.2023.10087686,
2. M. Dandekar, S. Lote and P. Dandekar, "Implementing the Power of Big Data Analytics," 2024 IEEE 3rd International Conference on Electrical Power and Energy Systems (ICEPES), Bhopal, India, 2024, pp. 1-5, doi: 10.1109/ICEPES60647.2024.10653580.
3. Subhendu Kumar Pani; Somanath Tripathy; George Jandieri; Sumit Kundu; Talal Ashraf Butt, "Applications of Machine Learning in Big-Data Analytics and Cloud Computing," in Applications of Machine Learning in Big-Data Analytics and Cloud Computing , River Publishers, 2021, pp.i-xxxii.
4. Amazon Web Services. (2023). Introducing the Next Generation of Amazon SageMaker: The Center for All Your Data Analytics and AI. Haettu osoitteesta: <https://aws.amazon.com/blogs/aws/introducing-the-next-generation-of-amazon-sagemaker-the-center-for-all-your-data-analytics-and-ai/> (30.12.2024)
5. Google Research. (n.d.). TensorFlow: A System for Large-Scale Machine Learning. Haettu osoitteesta: <https://research.google/pubs/tensorflow-a-system-for-large-scale-machine-learning/> (30.12.2024)
6. Google Open Source. (n.d.). TensorFlow Open Source Project. Haettu osoitteesta: <https://opensource.google/projects/tensorflow> (30.12.2024)
7. How Netflix Uses Python. (2023). TechRepublic: How Netflix Uses Python, Streaming Giant Reveals Its Programming Language, Libraries, and Frameworks. Haettu osoitteesta: <https://www.techrepublic.com/article/how-netflix-uses-python-streaming-giant-reveals-its-programming-language-libraries-and-frameworks/> (30.12.2024)
8. S. Johri, K. V. Rawal, B. Aishwarya, N. Singh, A. M. Shaaker and R. V, "Big Data and Artificial Intelligence: Revolutionizing Business Decision-Making," 2023 10th IEEE Uttar Pradesh Section International Conference on Electrical, Electronics and Computer Engineering (UPCON), Gautam Buddha Nagar, India, 2023, pp. 1689-1693, doi: 10.1109/UPCON59197.2023.10434500.
9. B. Jamalpur, P. Sarkar, M. H. Krishna, M. Lourens, K. S. Lakshmi and N. Singh, "Strategic Decision Making in the AI Age: Examining Neural Network Models in Business Management," 2024 International Conference on Communication, Computer Sciences and Engineering (IC3SE), Gautam Buddha Nagar, India, 2024, pp. 1496-1501, doi: 10.1109/IC3SE62002.2024.10593321.
10. Q. Sun, G. Chen and S. He, "Enterprise Development Decision Support System Based on Artificial Intelligence Technology," 2022 International Conference on Artificial Intelligence of Things and Crowdsensing (AIoTCs), Nicosia, Cyprus, 2022, pp. 245-249, doi: 10.1109/AIoTCs58181.2022.00044.